

TP08 - EM Algorithm

Machine Learning

Carranza-Alarcón Yonatan-Carlos¹

¹UMR CNRS 7253 Heudiasyc
Université de technologie de Compiègne

November 25, 2020

EM Algorithm

Soit la densité du mélange suivante

$$p(x; \theta) = \pi \varphi(x; \mu, \sigma) + (1 - \pi) \phi(x), \quad (1)$$

où $\varphi(\cdot; \mu, \sigma)$ est la fonction de densité de la loi normale $\mathcal{N}(\mu, \sigma)$ et $\phi(x)$ est la fonction de densité de la loi l'uniforme $\mathcal{U}(-a, a)$ (donc $\forall x, \phi(x) = \frac{1}{2a}$).

Problème: Soit l'échantillon $X = (X_1, \dots, X_n)$ issu de la densité $p(x, \theta)$ où $\theta = (\mu, \sigma, \pi)$ est inconnu. Donc, comment peut-on estimer les paramètres θ ?

- 1 Bayesian inference (MCMC/ABC)
- 2 Frequentist inference (Maximum likelihood estimation)

EM Algorithm

Maximum de vraisemblance: $\log L(\theta; x_1, \dots, x_n)$

$$\ell(\theta, X) = \sum_{i=1}^n \log \left(\pi \frac{1}{\sigma \sqrt{2(3.14)}} \exp \left(-\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2} \right) + (1 - \pi) \frac{1}{2a} \right)$$

Trop difficile, même parfois impossible, à résoudre!!!

Première dérivé $d(\mu)\ell(\theta, X) = 0$ et dérivé seconde $d(\mu)^2\ell(\theta, X) < 0$




$$\sum_{i=1}^n \frac{\pi \frac{1}{\sigma \sqrt{2(3.14)}} \exp \left(-\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2} \right)}{\pi \frac{1}{\sigma \sqrt{2(3.14)}} \exp \left(-\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2} \right) + (1 - \pi) \frac{1}{2a}} \left(-\frac{(x_i - \mu)}{\sigma^2} \right) (-1) = 0 \quad (2)$$

On verra que le terme en rouge est égal à l'espérance de notre variable latente, i.e. $\mathbb{E}_{y_i|x_i, \theta(t)}[y_i]$

Génération des données de la densité $p(x; \theta)$

$$\pi = 0.9, \mu = 2, \sigma = 1, a = 10, n = 1000$$

```
1 x <- rep(NA, n)
2 y <- rep(NA, n)
3 for(i in 1:n){
4   y[i] <- sample(c(1,0), size=1, prob=c(pi, 1-pi))
5   if(y[i]==1){
6     x[i] <- rnorm(1, mean=mu, sd=sigma)
7   } else {
8     x[i] <- runif(1, min=-a, max=a)
9   }
10 }
```



EM Algorithm - Formellement

On suppose qu'il exist variable aléatoire latente $Y \in \{1, \dots, k\}$ telle que (X, Y) peut partitionner le nuage de point X en k catégories.

E-Step:

$$Q(\theta, \theta^{(t)}) = \mathbb{E}_{Y|X, \theta^{(t)}} [\log L(\theta; X, Y)] \quad (3)$$

$$= \sum_Y P(Y|X, \theta^{(t)}) \log(L(\theta; X, Y)) \quad (4)$$

M-Step:

$$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta, \theta^{(t)}) \quad (5)$$

Loop: $|\ell(\theta^{(t)}; X) - \ell(\theta^{(t+1)}; X)| < \epsilon$

EM Algorithm - officieusement

E-Step: $\forall i \in \{1, \dots, n\}$ et $\theta^{(t)} = (\mu^{(t)}, \sigma^{(t)}, \pi^{(t)})$ fixé.

$$\hat{y}_i^{(t)} = \mathbb{E}_{y_i|x_i, \theta^{(t)}}[y_i] \quad (6)$$

M-Step:

$$\theta^{(t+1)} = \arg \max_{\theta} \mathbb{E}_{Y|X, \theta^{(t)}} [\log L(\theta; X, Y)] \quad (7)$$

Un cas particulier: Quand $y_i \in \{0, 1\}$

$$\hat{y}_i^{(t)} = P(y_i = 1|x_i, \theta^{(t)}) = \frac{P(y_i = 1, x_i|\theta^{(t)})}{P(x_i|\theta^{(t)})} \quad (8)$$

$$= \frac{\varphi(x; \mu^{(t)}, \sigma^{(t)})\pi^{(t)}}{\varphi(x; \mu^{(t)}, \sigma^{(t)})\pi^{(t)} + (1 + pi^{(t)})1/2a} \quad (9)$$

EM Algorithm

Comme, on procède (pour plus de détails [EM derivation.pdf \(moodle\)](#))

$$\mathbb{E}_{Y|X, \theta^{(t)}} [\log L(\theta; X, Y)] = \mathbb{E}_{Y|X, \theta^{(t)}} \left[\sum_{i=1}^n \log p(x_i, y_i | \theta) \right] = \sum_{i=1}^n \mathbb{E}_{y_i|x_i, \theta^{(t)}} [\log p(x_i, y_i | \theta)]$$

On calcule $\log p(x_i, y_i | \theta)$:

$$\log p(x_i, y_i | \theta) = y_i \log(\pi \phi(x_i, \mu, \sigma)) + (1 - y_i) \log((1 - \pi))$$

Et finalement l'espérance conditionnelle $\mathbb{E}_{y_i|x_i, \theta^{(t)}} [\log p(x_i, y_i | \theta)]$

$$\mathbb{E}_{y_i|x_i, \theta^{(t)}} [y_i] \log(\pi \phi(x_i, \mu, \sigma)) + (1 - \mathbb{E}_{y_i|x_i, \theta^{(t)}} [y_i]) \log((1 - \pi))$$

$\mathbb{E}_{y_i|x_i, \theta^{(t)}} [y_i]$ impossible à calculer sans $\theta^{(t)}$, et nécessaire pour maximiser l'espérance $\mathbb{E}_{Y|X, \theta^{(t)}} [\log L(\theta; X, Y)]$ dans l'étape M-step.

EM Algorithm (E-Step) in R

Pour un $\theta^{(t)} = (\mu^{(t)}, \sigma^{(t)}, \pi^{(t)})$

$$\hat{y}_i = \mathbb{E}_{y_i|x_i, \theta^{(t)}}[y_i] = \frac{\varphi(x; \mu^{(t)}, \sigma^{(t)})\pi^{(t)}}{\varphi(x; \mu^{(t)}, \sigma^{(t)})\pi^{(t)} + (1 - \pi^{(t)})1/2a}$$

```
1 # E-step
2 phi <- dnorm(x, mean=thetat[1], sd=thetat[2])
3 y<- phi*thetat[3]/(phi*thetat[3]+1/2a*(1-thetat[3]))
```


EM Algorithm (M-Step) in R

M-Step: En dérivant l'espérance $Q(\theta, \theta^{(t)})$, on obtient:

$$\hat{\pi}^{(t+1)} = \sum_{i=1}^n \hat{y}_i / n \quad (10)$$

$$\hat{\mu}^{(t+1)} = \frac{\sum_{i=1}^n \hat{y}_i x_i}{\sum_{i=1}^n \hat{y}_i} \quad (11)$$

$$\hat{\sigma}^{(t+1)} = \sqrt{\frac{\sum_{i=1}^n \hat{y}_i (x_i - \mu^{(t+1)})^2}{\sum_{i=1}^n \hat{y}_i}} \quad (12)$$

$$(13)$$

Donc le nouveau $\theta^{(t+1)} = (\hat{\mu}^{(t+1)}, \hat{\sigma}^{(t+1)}, \hat{\pi}^{(t+1)})$

```
1 # M-step
2 S <- sum(y)
3 pi <- S/n
4 mu <- sum(x*y)/S
5 sig <- sqrt(sum(y*(x-mu)^2)/S)
6 theta <- c(mu, sig, pi)
```

EM Algorithm (Condition d'arrêt) in R

Loop: $|\ell(\theta^{(t)}; X) - \ell(\theta^{(t+1)}; X)| < \epsilon'$

$$\ell(\theta_*; X) = \sum_{i=1}^n \log \left(\pi_* \frac{1}{\sigma_* \sqrt{2(3.14)}} \exp \left(-\frac{1}{2} \frac{(x_i - \mu_*)^2}{\sigma_*^2} \right) + (1 - \pi_*) \frac{1}{2a} \right)$$

```
1 loglik<- function(theta,x){  
2   phi <- dnorm(x,mean=theta[1],sd=theta[2])  
3   logL <- sum(log(theta[3]*phi+(1-theta[3])*1/2a))  
4   return(logL)  
5 }
```

EM Algorithm in R

```
1 logL0<- loglik(thetat,x)
2 while(go_on){
3   t <- t+1
4   # E-step
5   phi <- dnorm(x,mean=thetat[1],sd=thetat[2])
6   y<- phi*thetat[3]/(phi*thetat[3]+c*(1-thetat[3]))
7   # M-step
8   S <- sum(y)
9   pi <- S/n
10  mu <- sum(x*y)/S
11  sig <- sqrt(sum(y*(x-mu)^2)/S)
12  theta <- c(mu,sig,pi)
13  logL<-loglik(theta,x)
14  if (logL-logL0 < epsi){
15    go_on <- FALSE
16  }
17  logL0 <- logL
18  theta0<-theta print(c(t,logL))
19 }
```