

Recherche de composante(s) explicative(s) par pénalisation




UNIVERSITÉ
DE MONTPELLIER

Yonatan Carlos Carranza Alarcon

Superviseur: Xavier Bry

Soutenu: 25/06/2016



Plan

- I. Introduction
- II. Régression
- III. Modélisation
- IV. Résultats et Conclusions

I. Introduction

- Problématique:
 - L'absence d'échantillon nécessaire pour pouvoir appliquer des méthodes de régression linéaire classique.
 - Les variables explicatives p sont plus grand que l'échantillon n :
 - $\text{rang}(X) = p >>n$
 - $X'X$ n'est pas inversible
- Motivation:
 - Ce problème est souvent retrouvée dans le domaine de la médecine, la biologie, la chimique et autres, où le processus d'échantillon est très coûteux et parfois des longues périodes.
- Objectif
 - Proposer un modèle de régression qui améliore la précision de prévision. C'est-à-dire, ce dernier modèle doit minimiser l'erreur quadratique de prévision.

II. Régression


- Analyser la relation entre une variable par rapport à une autre ou plusieurs.
- Le plus connu est le modèle de régression linéaire.

$$Y = X\beta + \varepsilon$$

Y : variable à expliquer

X : variables explicatives

ε : erreur de mesure / bruit



Régression linéaire multiple gaussienne

- Pour de cas où $\text{rang}(X) \ll n$


- $\mathcal{H}_1 : \text{rang}(X) = p$

Modèle: $Y = X\beta + \varepsilon$

- $\mathcal{H}_2 : \mathbb{E}[\varepsilon] = 0, \Sigma_\varepsilon = \sigma^2 \mathbb{I}$

- $\mathcal{H}_3 : \varepsilon \sim \mathcal{N}(0, \sigma^2 \mathbb{I})$, ils sont i.i.d.

$$\mathcal{L}(Y; \beta, \sigma^2) = \prod_{i=1}^n f_Y(y_i) = \left(\frac{1}{2\pi\sigma^2} \right)^{n/2} \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \sum_{j=1}^p x_{i,j}\beta_j)^2 \right]$$



Régression Ridge

- Pour de cas où $\text{rang}(X) \gg n$
- Réduction de la valeurs des coefficients moins importantes et augmente plus importantes.
- Augmente les valeurs propres de la matrice $X'X$

$$\hat{\beta}_{ridge} = \arg \min \left[\sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p x_{i,j} \beta_j)^2 + k \sum_{j=1}^p \beta_j^2 \right]$$

$$\hat{\beta}_{ridge}(k) = (X'X + k\mathbb{I})^{-1} X'Y$$

K : valeur entre [0,1] et elle est stochastique.
 $(X'X + k\mathbb{I})$ est donc inversible.

Régression Composantes Principales

- Le but consiste à ne conserver qu'une partie des composantes principales(variabilité ou inertie global).
- Supprime l'information négligeable (ou bruit) qui n'apporte pas d'information important ou modèle.

Le modèle avec les k premières composantes : $\hat{Y} = X_1^* \beta_1^* + \dots + X_k^* \beta_k^* + \epsilon$

$$\begin{aligned}\hat{\beta}_{pcr}(k) &= (X^{*\prime} X^*)^{-1} X^{*\prime} Y \\ &= (X_{[1:k]}^{*\prime} X_{[1:k]}^*)^{-1} X_{[1:k]}^{*\prime} Y\end{aligned}$$

- Quand s'arrête ?
- Quel est le k optimum ?


Régression de moindre carré partiels

- Le but consiste à trouver des nouvelles variables explicatives \mathbf{T} à partir des combinaisons linéaires de la variable explicative départ \mathbf{X} .
- Ces dernières variables ne seront pas ajustées par la part de la variabilité qui représente les variables explicatives originales (comme PCR) sinon par leur lien avec la variable à expliquer \mathbf{Y} .

$$t^{(k)} = \arg \max_{\substack{t=X^{(k-1)}w, w \in \mathbb{R}^p \\ w'w=1}} \langle t, Y^{(k)} \rangle$$

$$\underline{Y^{(k)} = r_k t^{(k)} + \hat{\epsilon}_k}$$

- Quand s'arrête ?
- Quel est le k optimum ?



III. Modélisation

Les régresseurs (ou variables explicatives) sont partitionnés en deux groupes : $X = \{x^1, \dots, x^p\}$, dans lequel nous cherchons à faire de la réduction dimensionnelles sous la forme d'une combinaison linéaire x_j , et $T = \{f^1, \dots, f^K\}$, qui rassemblera les K composantes principales trouvées de X .

$$Y = X\beta + T\delta + \epsilon ; \quad \epsilon \sim N(0; \sigma^2 \mathbb{I})$$

$$\text{où } \beta = \gamma u \text{ et } u'u = 1$$

$$\text{donc } \gamma = \|\beta\| \text{ et } u = \frac{\beta}{\|\beta\|}$$

$$\mathcal{G} = \arg \max_{\substack{\delta, \gamma, \sigma^2, u \\ u'u=1}} [(1-s)\ell + sS(u)]$$

Où, ℓ est la log-vraisemblance de $f_Y \sim N(X\beta + T\delta; \sigma^2 \mathbb{I})$

Modèle univarié – T vide

La modélisation: $Y \sim N(X\beta + T\delta; \sigma^2 \mathbb{I})$

$$\mathcal{L}(Y; u, \gamma, \sigma^2) = \prod_{i=1}^n f_Y(y_i) = \left(\frac{1}{2\pi\sigma^2} \right)^{n/2} \exp \left(-\frac{1}{2\sigma^2} \|Y - X\beta\|^2 \right)$$

$$\mathcal{G}' = \arg \max_{\substack{\gamma, \sigma^2, u \\ u'u=1}} \left[(s-1) \frac{n \ln(\sigma^2)}{2} + (s-1) \frac{\|Y - X\beta\|^2}{2\sigma^2} + su'Nu \right]$$

$$\begin{aligned} \text{On pose : } \Omega &= \left[(s-1)\gamma^2 X'X + 2\sigma^2(sN - \lambda \mathbb{I}) \right] \\ \iff \hat{u} &= \gamma(s-1)\Omega^{-1}X'Y \end{aligned}$$

- Le valeur de réglage s est stochastique, elle s'adapte aux données.
- Cependant la matrice Ω pendant l'optimisation n'est pas inversible !!!!

Modèle univarié – T vide

Théorème 2.1 Soit X une matrice $m \times p$ dont les coefficients appartiennent au corps K , où $K = \mathbb{R}$ ou $K = \mathbb{C}$. Alors il existe une factorisation, nommée Décomposition en Valeurs Singulières de X , de la forme :

$$X = U\Sigma V'$$

Où si $K = \mathbb{R}$, les matrices unitaires sont de matrices orthogonales et :

- U une matrice unitaire $m \times m$ sur K .
- Σ une matrice diagonale rectangulaire $m \times n$ dont les coefficients diagonaux sont des réels positifs ou nuls et tous les autres sont nuls.
- V est la matrice unitaire $n \times n$ sur K .

En appliquant le théorème 2.1 dans notre estimateur u , nous avons donc :

$$\begin{aligned} X = U\Sigma V' &\iff X'X = V\Sigma^2V' \text{ et } N = V\Sigma W^* \Sigma V', \text{ où } W^* = U'WU \\ &\iff \Omega^* = [(s-1)\hat{\gamma}^2\Sigma^2 + 2\hat{\sigma}^2(s\Sigma W^* \Sigma - \hat{\lambda}\mathbb{I})] \\ &\iff \hat{u} = \hat{\gamma}(s-1)V\Omega^{*-1}\Sigma U'Y \end{aligned} \tag{2.13}$$

D'où, la matrice Ω^* est une matrice carrée diagonale et elle est donc pseudo-inversible.

Modèle univarié – T non vide

La modélisation: $Y \sim N(X\beta + T\delta; \sigma^2 \mathbb{I})$

$$\mathcal{L}_Y(X, T; u, \delta, \gamma, \sigma^2) = \prod_{i=1}^n f_Y(y_i) = \left(\frac{1}{2\pi\sigma^2} \right)^{n/2} \exp \left(-\frac{1}{2\sigma^2} \|Y - X\beta - T\delta\|^2 \right)$$

$$Q = \underset{\substack{\delta, \gamma, \sigma^2, u \\ u'u=1 \\ u'_k X' W X u = 0}}{\arg \max} \left[(s-1) \frac{n \ln(\sigma^2)}{2} + (s-1) \frac{\|Y - \gamma X u - T \delta\|^2}{2\sigma^2} + s u' N u \right]$$

Définition 2.1 Nous soumettrons à notre programme à optimiser la contrainte d'orthogonalité aux composantes principales précédents. C'est-à-dire : $\forall k \in \{1, \dots, K\}$, $f_k = X u_k$ et $F^{k-1} = [f^1, \dots, f^{k-1}]$;


$$\forall k : f^1, \dots, f^{k-1} \perp f^k \iff F^{k-1} W f^k = 0 \iff F^{k-1} W X u_k = 0$$

D'où, la covariance des composantes principales est : $\text{cov}(f_i, f_j) = 0, \forall i, j \in \{1, \dots, K\}$ et $j \neq i$.

Modèle univarié – T non vide

- Étape (1):

$$Q' = \arg \max_{\delta, \gamma, \sigma^2} \left[n \ln(\sigma^2) + \frac{\|Y - \gamma X \hat{u}_{[t]} - T\delta\|^2}{\sigma^2} \right]$$



$$Q'' = \arg \max_{\delta, \gamma, \sigma^2} \left[n \ln(\sigma^2) + \frac{\|Y - Z\Lambda\|^2}{\sigma^2} \right]$$

$$\hat{\Lambda} = (Z'Z)^{-1}Z'Y$$

$$\hat{\Lambda} = (\hat{\gamma}, \hat{\delta})'$$

Modèle univarié – T non vide

- Étape (2):

$$\mathcal{Q}''' = \arg \max_{\substack{u, u'u=1 \\ A'_k u=0}} \left[(s-1) \frac{\|Y - \hat{\gamma}_{[t]} X u - T \hat{\delta}_{[t]}\|^2}{2\hat{\sigma}_{[t]}^2} + su'Nu \right]$$

où $A'_k = u_k X' W X$

$$\text{où } A'_k = u'_k X' W X \iff A'_k u = 0, \forall k \in \{1, 2, \dots, K\}$$

Nous posons : $\Omega = \left[(s-1)\hat{\gamma}^2 X' X + 2\hat{\sigma}^2(sN - \hat{\lambda}\mathbb{I}) \right]$

$$\iff \hat{u}_{[t+1]} = \Omega^{-1} \left[\hat{\gamma}(s-1)X' (Y - T\hat{\delta}) + \hat{\sigma}^2 A_k \hat{\tau} \right]$$

Ω Pas inversible, encore SVD !!!!

En posant : $\Omega^* = \left[(s-1)\hat{\gamma}^2 \Sigma^2 + 2\hat{\sigma}^2(s\Sigma W^* \Sigma - \hat{\lambda}\mathbb{I}) \right]$, où : $W^* = U' W U$

$$X = U \Sigma V' \iff \hat{u}_{[t+1]} = V \Omega^{*-1} \left[\hat{\gamma}(s-1)\Sigma U' (Y - T\hat{\delta}) + \hat{\sigma}^2 \Sigma W^* \Sigma V' u_k \hat{\tau} \right] \quad (2.28)$$

- Condition d'arrêt:

$$\|\hat{u}_{[t]} - \hat{u}_{[t+1]}\|^2 > 10^{-6} \text{ ou } \langle \hat{u}_{[t]} | \hat{u}_{[t+1]} \rangle^2 < 1 - 10^{-6}.$$

Validation du modèle de régression

- Centrage et réduction

$$\hat{\sigma}_{X_j} = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 / n$$

$$\tilde{X} = (X_j - \bar{x}_j \mathbb{I}) / \hat{\sigma}_{X_j} \quad \bar{x}_j = \sum_{i=1}^n x_{ij} / n \quad \tilde{Y} = Y - \bar{y}$$

- Prévision d'un nouveau échantillon

$$\hat{y}_{x b r y, n+1}^p = \left[\sum_{j=1}^p \left(\frac{x_{n+1,j} - \bar{x}_j}{\hat{\sigma}_{X_j}} [\hat{\beta}_{x b r y}(\tilde{s})]_j \right) \right] + \left[\sum_{j=1}^p \left(\frac{x_{n+1,j} - \bar{x}_j}{\hat{\sigma}_{X_j}} [\hat{u}_k(\tilde{s}) \hat{\delta}(\tilde{s})]_j \right) \right] + \bar{y}$$

- Apprentissage et Validation Croisé

$$PRESS(s) = \left\| \hat{Y}_{x b r y, v}^p(s) - Y_v \right\|^2$$

(\tilde{X}_a, \tilde{Y}_a) et (\tilde{X}_v, \tilde{Y}_v)

$\hat{s} = \arg \min_{s \in]0,1[} \left\| \hat{Y}_{x b r y, v}^p(s) - Y_v \right\|^2$


Choisir minimum

IV. Résultats et Conclusions

Jeu de données


- Nous sommes en présence de biscuits non cuits pour lesquels nous souhaitons connaître rapidement et à moindre coût, la composition en quatre ingrédients : les lipides, les sucres, la farine et l'eau
- Processus alternatif est la mesure d'un spectre d'absorbance dans le domaine proche infrarouge. Ce processus nous donne 700 variables explicatives pour trouver la composition du biscuit non cuit.
- Echantillons de validation et apprentissage:
 - 700 Variables explicatives
 - 40 biscuits non cuits pour l'apprentissage
 - 32 biscuits non cuits pour la validation

Première Composante Principale



Modèle de Regression	Paramètre de réglage/nb. Composantes	EMQ*
Moindre carrés multiple	—	4304
Ridge	0.1081081	4.95
Composantes principales (PCR)	3 Comps.	1.03
Moindres carrés partiels (PLS)	5 Comps.	0.78
Nouvelle approche	T vide et 0.998	14.79

K Composante principale permises



Modèle de Regression	Paramètre de réglage/nb. Composantes	EMQ*
Moindres carrés multiples	—	4304
Ridge	0.1081081	4.95
Composantes principales (PCR)	3 Comps.	1.03
Moindres carrés partiels (PLS)	5 Comps.	0.78
Nouvelle approche	T avec 2 comps. et 0.9391	9.8264
Nouvelle approche	T avec 5 comps. et 0.9451	9.8277

Avec 2 composantes à peu près 98% Information ACP

Conclusions

- La généralisation du modèle de régression univariée à un modèle multivariée (i.e. la variable explicative a plusieurs colonnes à expliquer), aurait été intéressante à l'analyser et le comparer avec les méthodes existantes.
- Enfin et le plus intéressant aurait été de modéliser autres variantes de la fonction de pertinence structurelle $S(u)$, par exemple :

$$S(u) = \left(\sum_{j=1}^J (u' N_j u)^l \right)^{1/l}.$$



Des questions ?